

人工智能理论作业 4

数据科学与计算机学院

18340082 邝金熙

1. 决策树

首先计算整个数据集的信息熵：一共有 18 个样本，分类为 skips 的有 9 个，为 reads 的有 9 个，概率均为 0.5. 故 $H_0 = -(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}) = 1$.

若根据作者是否有名进行分类，则可计数得 18 个样本中有 12 个作者有名，6 个作者不出名；12 个作者有名的样本中 3 个为 skips, 6 个为 reads；6 个作者有名的样本中 3 个为 skips, 3 个为 reads；从而可以计算对作者是否有名进行分裂之后的信息增益：

$$\begin{aligned} Gain_{0A} &= H_0 - H_{0A} \\ &= H_0 - (\frac{12}{18}(-(\frac{6}{12}\log_2\frac{6}{12} + \frac{6}{12}\log_2\frac{6}{12})) + \frac{6}{18}(-(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}))) \\ &= 0 \end{aligned}$$

同理根据该书是新作还是续作、该书的篇幅长短、该书的阅读场所是在家还是工作地，依次计算其信息增益可以得到：

$$\begin{aligned} Gain_{0B} &= H_0 - H_{0B} \\ &= H_0 - (\frac{10}{18}(-(\frac{3}{10}\log_2\frac{3}{10} + \frac{7}{10}\log_2\frac{7}{10})) + \frac{8}{18}(-(\frac{6}{8}\log_2\frac{6}{8} + \frac{2}{8}\log_2\frac{2}{8}))) \\ &= 0.1498258895566673 \end{aligned}$$

$$\begin{aligned} Gain_{0C} &= H_0 - H_{0C} \\ &= H_0 - (\frac{7}{18}(-(\frac{7}{7}\log_2\frac{7}{7} + \frac{0}{7}\log_2\frac{0}{7})) + \frac{11}{18}(-(\frac{2}{11}\log_2\frac{2}{11} + \frac{9}{11}\log_2\frac{9}{11}))) \\ &= 0.581968199340573 \end{aligned}$$

$$\begin{aligned} Gain_{0D} &= H_0 - H_{0D} \\ &= H_0 - (\frac{8}{18}(-(\frac{4}{8}\log_2\frac{4}{8} + \frac{4}{8}\log_2\frac{4}{8})) + \frac{10}{18}(-(\frac{5}{10}\log_2\frac{5}{10} + \frac{5}{10}\log_2\frac{5}{10}))) \\ &= 0 \end{aligned}$$

注意到其中 $1\log_2 1 = 0, 0\log_2 0 = 0$, 第二个等式是因为 $\frac{1}{x}$ 是 $\log_2 x$ 的高阶无穷小。

比较四个信息增益可以发现按篇幅长短分裂得到的增益最大, 分裂出两个子节点: 篇幅长的节点包含 7 个样本, 全部为 skips 类, 不需要再分裂; 篇幅短的节点包含 9 个样本, 其中 2 个 skips, 9 个 reads, 因此需要再次分裂。重复上述步骤计算信息增益:

$$H_1 = -\left(\frac{2}{11}\log_2 \frac{2}{11} + \frac{9}{11}\log_2 \frac{9}{11}\right) = 0.6840384356390418$$

$$\begin{aligned} Gain_{1A} &= H_1 - H_{1A} \\ &= H_1 - \left(\frac{6}{11}\left(-\left(\frac{0}{6}\log_2 \frac{0}{6} + \frac{6}{6}\log_2 \frac{6}{6}\right)\right) + \frac{5}{11}\left(-\left(\frac{2}{5}\log_2 \frac{2}{5} + \frac{3}{5}\log_2 \frac{3}{5}\right)\right)\right) \\ &= 0.24268559765261632 \end{aligned}$$

$$\begin{aligned} Gain_{1B} &= H_1 - H_{1B} \\ &= H_1 - \left(\frac{7}{11}\left(-\left(\frac{0}{7}\log_2 \frac{0}{7} + \frac{7}{7}\log_2 \frac{7}{7}\right)\right) + \frac{4}{11}\left(-\left(\frac{2}{4}\log_2 \frac{2}{4} + \frac{2}{4}\log_2 \frac{2}{4}\right)\right)\right) \\ &= 0.3203884701990212 \end{aligned}$$

$$\begin{aligned} Gain_{1D} &= H_1 - H_{1D} \\ &= H_1 - \left(\frac{5}{11}\left(-\left(\frac{1}{5}\log_2 \frac{1}{5} + \frac{4}{5}\log_2 \frac{4}{5}\right)\right) + \frac{6}{11}\left(-\left(\frac{1}{6}\log_2 \frac{1}{6} + \frac{5}{6}\log_2 \frac{5}{6}\right)\right)\right) \\ &= 0.0013316170638657532 \end{aligned}$$

比较三个信息增益可以发现按新作还是续作分裂得到的增益最大, 分裂出两个子节点: 新作的节点包含 7 个样本, 全部为 reads 类, 不需要再分裂; 续作的节点包含 4 个样本, 其中 2 个 skips, 2 个 reads, 因此需要再次分裂。重复上述步骤计算信息增益:

$$H_2 = -\left(\frac{2}{4}\log_2 \frac{2}{4} + \frac{2}{4}\log_2 \frac{2}{4}\right) = 1$$

$$\begin{aligned} Gain_{2A} &= H_2 - H_{2A} \\ &= H_2 - \left(\frac{2}{4}\left(-\left(\frac{0}{2}\log_2 \frac{0}{2} + \frac{2}{2}\log_2 \frac{2}{2}\right)\right) + \frac{2}{4}\left(-\left(\frac{2}{2}\log_2 \frac{2}{2} + \frac{0}{2}\log_2 \frac{0}{2}\right)\right)\right) \\ &= 1 \end{aligned}$$

$$\begin{aligned} Gain_{2D} &= H_2 - H_{2D} \\ &= H_2 - \left(\frac{2}{4}\left(-\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}\right)\right) + \frac{2}{4}\left(-\left(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}\right)\right)\right) \\ &= 0 \end{aligned}$$

比较两个信息增益可以发现按作者是否出名得到的增益最大，分裂出两个子节点：作者出名的节点包含 2 个样本，全部为 reads 类，不需要再分裂；作者不出名的节点包含 2 个样本，全部为 skips 类，不需要再分裂；最终得到的决策树如图 1 所示，边上的文字为判断依据，圈内的文字为所预测的类：

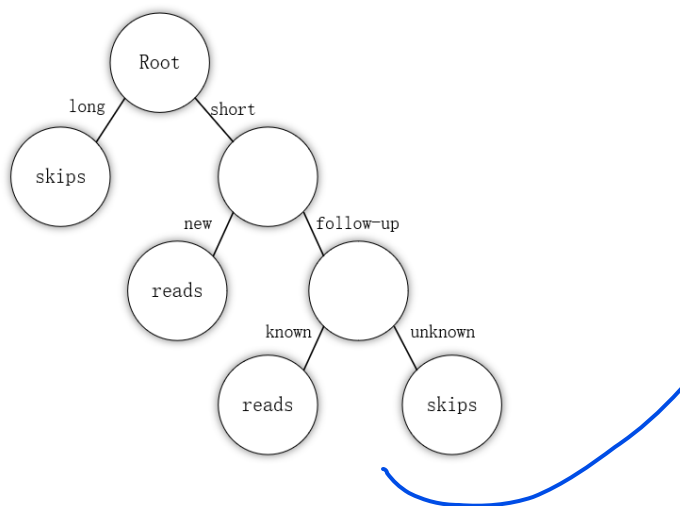


图 1: 决策树

2. 概率论推理

Notation: 本题中 h_i 表示第 i 个假设， d 表示已经出现的事实， X 表示预测的类别。

(a) Bayesian

根据贝叶斯推理，我们有：

$$\begin{aligned}
 P(h_i|d) &= \frac{P(h_i, d)}{P(d)} = \frac{P(d|h_i) * P(h_i)}{P(d)} \\
 P(X|d) &= \sum_i P(X|h_i)P(h_i|d) \\
 &= \sum_i P(X|h_i) \frac{P(d|h_i) * P(h_i)}{P(d)} \\
 &= \frac{\sum_i P(X|h_i)P(d|h_i)P(h_i)}{\sum_i P(d|h_i)P(h_i)}
 \end{aligned}$$

其中 $P(h_i)$ 为每种假设的先验概率, 根据题设依次为 0.1, 0.2, 0.4, 0.2, 0.1; $P(X|h_i)$ 为每种假设下猜测为樱桃味或青柠味的概率, 如 $P(cherry|h_1) = 100\%$; $P(d|h_i)$ 为在该假设下出现 d 的概率, 本题中 $d=[lime, cherry, cherry, lime, lime]$, 例 $P(d|h_1) = 1^2 * 0^3 = 0$, $P(d|h_2) = 0.75^2 * 0.25^3 = 0.008789$ 。

根据上述规则代入本题数据得

$$P(cherry|d) = 0.455$$

$$P(lime|d) = 0.545$$

即在贝叶斯学习中下一颗为青柠味的可能性略大, 预测下一颗出现的是青柠味的糖果。

(b) MAP

在最大后验方法中, 比较各种假设在考虑先验概率后的, 在当前事实下出现的可能性, 取可能性最大的一种作为当前假设, 再根据该假设预测。即

$$h_{MAP} = \operatorname{argmax}_h P(h_i|d) = \operatorname{argmax}_h \frac{P(d|h_i)P(h_i)}{P(d)}$$

其中对于所有假设 $P(d)$ 均相同, 故只需要比较分子部分。代入数据得:

$$P(d|h_1)P(h_1) = 0$$

$$P(d|h_2)P(h_2) = 0.0017578125$$

$$P(d|h_3)P(h_3) = 0.0125$$

$$P(d|h_4)P(h_4) = 0.0052734375$$

$$P(d|h_5)P(h_5) = 0$$

从而有 $h_{MAP} = h_3$, 在假设 h_3 中, 出现樱桃味和青柠味的概率均为 50%, 故预测两种情况的出现概率相等。

(c) ML

在最大似然方法中, 比较当前事实在各种假设下出现的可能性, 取可能性最大的一种作为当

前假设，再根据该假设预测。即

$$h_{ML} = \operatorname{argmax}_h P(d|h_i)$$

代入数据得：

$$P(d|h_1) = 0$$

$$P(d|h_2) = 0.0087890625$$

$$P(d|h_3) = 0.03125$$

$$P(d|h_4) = 0.0263671875$$

$$P(d|h_5) = 0$$

从而有 $h_{ML} = h_3$ ，在假设 h_3 中，出现樱桃味和青柠味的概率均为 50%，故预测两种情况的出现概率相等。

3. 朴素贝叶斯分类

首先构建真值表如表 1 所示。

不妨记事件 $A = 1$ 为 a ， $A = 0$ 为 $\neg a$ ，则：

$$\begin{aligned} P(e|abcd) &= \frac{P(abcde)}{P(abcd)} \\ &= \frac{P(a|e)P(b|e)P(c|e)P(d|e)P(e)}{P(abcd)} \\ P(\neg e|abcd) &= \frac{P(abcd\neg e)}{P(abcd)} \\ &= \frac{P(a|\neg e)P(b|\neg e)P(c|\neg e)P(d|\neg e)P(\neg e)}{P(abcd)} \end{aligned}$$

由于两式分母相同，故只需要比较分子。在已有的 15 个样本中 $E=1$ 的有 4 个， $E=0$ 的有 11 个，故 $P(e) = \frac{4}{15}$ ， $P(\neg e) = \frac{11}{15}$ ；在 $E=1$ 的 4 个样本中， $A=1$ 的样本有 2 个，故 $P(a|e) = \frac{2}{4}$ ；在 $E=0$ 的 11 个样本中， $A=1$ 的样本有 5 个，故 $P(a|\neg e) = \frac{5}{11}$ ；同理可数得 $P(b|e) = P(c|e) = P(d|e) = \frac{2}{4}$ ，

A,B,C,D,E				
0	0	0	0	0
0	0	0	1	0
0	0	1	0	0
0	0	1	1	0
0	1	0	0	0
0	1	0	1	1
0	1	1	0	1
0	1	1	1	0
1	0	0	0	0
1	0	0	1	1
1	0	1	0	1
1	0	1	1	0
1	1	0	0	0
1	1	0	1	0
1	1	1	0	0

表 1: 真值表

$P(b|\neg e) = P(c|\neg e) = P(d|\neg e) = \frac{5}{11}$, 代入上述数据得:

$$P(e|abcd) = \frac{0.016666666666666666}{P(abcd)}$$

$$P(\neg e|abcd) = \frac{0.03130478337089907}{P(abcd)}$$

从而有 $P(e|abcd) < P(\neg e|abcd)$, 即预测当输入为 $A=B=C=D=1$ 时, 输出 $E=0$ 。该预测结果与真实结果 $1 \oplus 1 \wedge 1 \oplus 1 = 0$ 吻合。

4. 异或神经网络

根据布尔代数知识，我们有 $A \oplus B = A\bar{B} + \bar{A}B$ ，从而我们可以构建类似 ML 课件 3 第 24 页的主析取范式网络，即隐藏层神经元计算合取，输出层神经元计算析取，神经元中的激活函数采用 0-1 示性函数，即输入大于 0 输出 1，否则输出 0，如图 2 所示：

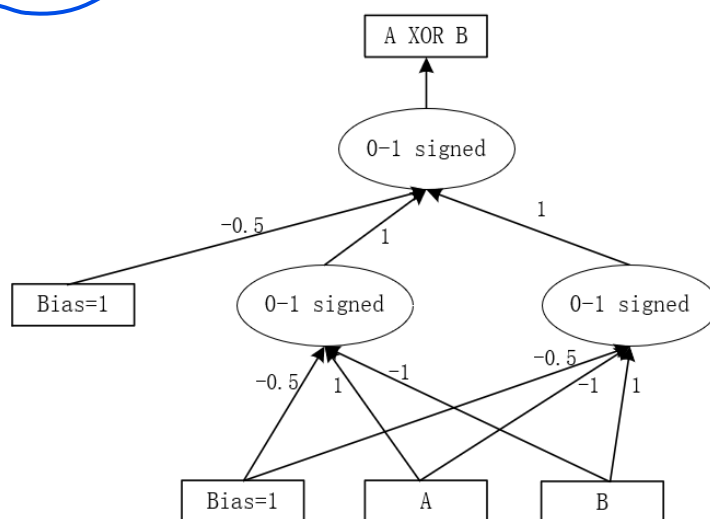


图 2: 异或神经网络

下列表验证该神经网络的正确性，每一列分别表示 A, B, 隐藏层左侧神经元输入, 隐藏层左侧神经元输出, 隐藏层右侧神经元输入, 隐藏层右侧神经元输出, 输出层神经元输入, 输出层神经元输出：

A	B	In1	Out1	In2	Out2	In3	Out3
0	0	-0.5	0	-0.5	0	-0.5	0
0	1	-1.5	0	0.5	1	0.5	1
1	0	0.5	1	-1.5	0	0.5	1
1	1	-0.5	0	-0.5	0	-0.5	0

表 2: 异或神经网络验证表

可以看到该神经网络的真值表与异或运算的真值表相同，符合题目要求。

5. 计算损失对权重的偏导

首先推导任一损失对任一权重的偏导，此处 $g()$ 为激活函数， a_k 为输出层第 k 个神经元的输出， y_k 表示输出层第 k 个神经元的真实结果， $Loss_k$ 表示第 k 个输出层神经元的损失，损失函数使用平方损失函数， ω_{ij} 表示起点为该层第 i 个神经元，终点为该层第 j 个神经元的边的权重，与题目中的表示方法不同。使用 i_0, j_0 是为了避免与求和时的循环变量 i, j 混淆，造成像课件中的理解困难。对于只有一个隐藏层的网络， i 表示输入层计数， j 表示隐藏层计数， k 表示输出层计数：

$$\begin{aligned}
 \frac{\partial Loss_k}{\partial \omega_{i_0 j_0}} &= \frac{\partial ||y_k - a_k||^2}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) \frac{\partial g(\sum_j \omega_{jk} a_j)}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \frac{\partial \sum_j \omega_{jk} a_j}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \frac{\partial \omega_{j_0 k} a_{j_0}}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \omega_{j_0 k} \frac{\partial a_{j_0}}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \omega_{j_0 k} \frac{\partial g(\sum_i \omega_{i j_0} a_i)}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \omega_{j_0 k} g'(\sum_i \omega_{i j_0} a_i) \frac{\partial \omega_{i_0 j_0} a_i}{\partial \omega_{i_0 j_0}} \\
 &= -2(y_k - a_k) g'(\sum_j \omega_{jk} a_j) \omega_{j_0 k} g'(\sum_i \omega_{i j_0} a_i) a_{i_0}
 \end{aligned}$$

(a) $\partial Loss_{o1} / \partial \omega_1$

要计算的 $Loss_{o1}$ 相当于上述推导中的 $Loss_1$ ， ω_1 相当于 $\omega_{i=1, j=1}$ 。

首先计算得到 $a_{k=1} = 0.751365$ ，从课件题目图片中可以得到 $y_1 = 0.01$ ，输出层第 1 个神经元的输入 $\sum_j \omega_{j1} a_j = 1.105906$ ，对 sigmoid 函数的导数为 $g'(\sum_j \omega_{j1} a_j) = g(\sum_j \omega_{j1} a_j) * (1 - g(\sum_j \omega_{j1} a_j)) = 0.186816$ ， $\omega_{j=1, k=1} = \omega_5 = 0.4$ ，隐藏层第 1 个神经元的输入 $\sum_i \omega_{i1} a_i = 0.3775$ ，对 sigmoid 函数的导数为 $g'(\sum_i \omega_{i1} a_i) = g(\sum_i \omega_{i1} a_i) * (1 - g(\sum_i \omega_{i1} a_i)) = 0.2413$ ， $a_1 = 0.05$ ，因此：

$$\frac{\partial Loss_{o1}}{\partial \omega_1} = -2(y_1 - a_1) g'(\sum_j \omega_{j1} a_j) \omega_{j=1, k=1} g'(\sum_i \omega_{i1} a_i) a_1 = 0.0013367920422887463$$

(b) $\partial Loss_{o2} / \partial \omega_4$

要计算的 $Loss_{o2}$ 相当于上述推导中的 $Loss_2$, ω_4 相当于 $\omega_{i=2,j=2}$ 。

首先计算得到 $a_{k=2} = 0.755531$, 从课件题目图片中可以得到 $y_1 = 0.99$, 输出层第 2 个神经元的输入 $\sum_j \omega_{j2} a_j = 0.985721$, 对 \tanh 函数的导数为 $g'(\sum_j \omega_{j2} a_j) = 1 - g(\sum_j \omega_{j2} a_j)^2 = 0.429171$, $\omega_{j=2,k=2} = \omega_8 = 0.55$, 隐藏层第 2 个神经元的输入 $\sum_i \omega_{i2} a_i = 0.3925$, 对 \tanh 函数的导数为 $g'(\sum_i \omega_{i2} a_i) = 1 - g(\sum_i \omega_{i2} a_i)^2 = 0.860488$, $a_2 = 0.1$, 因此:

$$\frac{\partial Loss_{o2}}{\partial \omega_4} = -2(y_2 - a_2)g'(\sum_j \omega_{j2} a_j)\omega_{j=2,k=2}g'(\sum_i \omega_{i2} a_i)a_2 = -0.009525402681050708$$